

프로젝트: Amazon 데이터셋 기반 추천 시스템 설계

분석자 : 박의진

분석일 : 2025.12.10

[공통 데이터셋 준비]

I. Preprocessing step

1. 원본 데이터 (<https://www.kaggle.com/datasets/karkavelrajaj/amazon-sales-dataset>) 구조와 타입 확인

- 주요 컬럼 타입
 - discounted_price, actual_price, discount_percentage : FLOAT
 - rating_count : INTEGER
 - rating, category, about_product, review_*, user_id 등: STRING
- → 평점(rating)은 **STRING → FLOAT 변환 필요**,
→ 카테고리의 상위 카테고리를 추출(맨 앞에 부분만 파싱)해서 사용하기로 결정.

2. 결측치와 이상치 확인 후 전처리하여 분석용 테이블 생성

- 전체 행 : 1465행, rating_count 결측 2개 → 제외 시키기
- 이상치(음수나, 너무 말도 안되는 가격 등)는 min, max값 확인했을 때 관찰되지 않았음. → 나머지 그대로 감

```
-- 0. 데이터셋 확인
SELECT *
FROM `project-5278bde0-2369-4e6d-8e7.d4.amazon`
LIMIT 100;

-- 0.1. 컬럼별 타입 확인 : rating이 숫자인데 string으로 되어있다! -> 변경 필요
SELECT
  column_name,
  data_type
FROM `project-5278bde0-2369-4e6d-8e7.d4`.`INFORMATION_SCHEMA.COLUMNS`
WHERE table_name = 'amazon';

--0.2. 결측치 개수 확인 (총 1465행에서 rating_count만 2개 결측있음)
SELECT
  COUNT(*) AS total_rows,
  COUNTIF(rating IS NULL) AS missing_rating,
  COUNTIF(rating_count IS NULL) AS missing_rating_count,
  COUNTIF(discount_percentage IS NULL) AS missing_discount_percentage,
  COUNTIF(discounted_price IS NULL) AS missing_discounted_price,
  COUNTIF(actual_price IS NULL) AS missing_actual_price,
  COUNTIF(category IS NULL) AS missing_category
FROM `project-5278bde0-2369-4e6d-8e7.d4.amazon`;

--0.3. 이상치 탐색 (값 범위 확인 결과나 음수나 아주 고가 이상한 가격 등은 확인 되지 않음)
SELECT
  MIN(SAFE_CAST(rating AS FLOAT64)) AS min_rating,
  MAX(SAFE_CAST(rating AS FLOAT64)) AS max_rating,
  MIN(rating_count) AS min_rating_count,
  MAX(rating_count) AS max_rating_count,
  MIN(discount_percentage) AS min_discount,
  MAX(discount_percentage) AS max_discount,
  MIN(discounted_price) AS min_disc_price,
  MAX(discounted_price) AS max_disc_price,
  MIN(actual_price) AS min_actual_price,
  MAX(actual_price) AS max_actual_price
FROM `project-5278bde0-2369-4e6d-8e7.d4.amazon`;
```

3. 전처리해서 분석용 새로운 테이블 만들기

```
CREATE OR REPLACE TABLE `project-5278bde0-2369-4e6d-8e7.d4.amazon_uj` AS
WITH base AS (
  SELECT
    product_id,
    product_name,
    SPLIT(category, '|')[SAFE_OFFSET(0)] AS top_category,

    discounted_price,
    actual_price,
    discount_percentage,

    SAFE_CAST(rating AS FLOAT64) AS rating,
    rating_count,

    about_product,
    review_title,
    review_content,
    user_id,
    user_name,
    review_id,

    img_link,
    product_link
  FROM `project-5278bde0-2369-4e6d-8e7.d4.amazon`
  WHERE rating_count IS NOT NULL
    AND SAFE_CAST(rating AS FLOAT64) IS NOT NULL;
)
```

- **결측 없고 총 행 1462인 분석용 새 테이블 생성, (product_id 기준으로 중복 2-3행씩 존재한다는 것 확인함)**

The screenshot shows a BigQuery console with a SQL query and its results. The query is as follows:

```
1 SELECT *
2 FROM `project-5278bde0-2369-4e6d-8e7.d4.amazon_uj`
3 LIMIT 1000;
4
5 SELECT
6   COUNT(*) AS total_rows,
7   COUNTIF(rating IS NULL) AS missing_rating,
8   COUNTIF(rating_count IS NULL) AS missing_rating_count
9 FROM `project-5278bde0-2369-4e6d-8e7.d4.amazon_uj`;
```

The results table shows the following data:

row	total_rows	missing_rating	missing_rating_count
1	1462	0	0

The right sidebar shows the schema of the table `project-5278bde0-2369-4e6d-8e7.d4.amazon\_uj` with columns: product_id, product_name, top_category, discounted_price, actual_price, discount_percentage, rating, rating_count, about_product, review_title, review_content, user_id, user_name, review_id, img_link, product_link.

추천 시스템 1. 카테고리별 초특가 베스트딜 TOP 10

1. 추천 시스템 이름

카테고리별 초특가 베스트딜 Top 10 추천

2. 추천 시스템 테마/컨셉

본 데이터셋에서 상품수가 많이 등록되어 있는 상위 3개 카테고리 (Electronics, Home&Kitchen, Computers&Accessories)를 대상으로, 고객이 “정말 할인율이 높고, 리뷰로 충분히 검증된 인기 상품”만 빠르게 찾을 수 있도록 구성한 추천 시스템임.

EDA 결과, 카테고리별 평균 할인율이 비슷하게 나타나 단순히 평균 대비 필터링하는 방식은 차별성이 없었음. 또한 리뷰수 분포가 카테고리마다 크게 달라 절대 리뷰수 기준을 적용하면 왜곡될 위험이 컸음.

따라서 본 시스템은 아래와 같은 기준을 염두하여 2단 필터링 + 정렬 방식으로 추천 품질을 극대화하도록 함.

- 카테고리 내 리뷰수 상위 30% 이상에 해당 (rating_count)

- 평점 조건 4.0-5.0점 (rating)에 해당
- 상기 두 조건을 충족하는 상품 중 카테고리 내 할인율 TOP 10위 선발 (discount_percentage)

3. 구현 로직 배경 : EDA를 통한 인사이트 도출

(1) EDA 1. 카테고리별 상품 수 파악

- 총 9개의 top_category가 존재하였으나, 상위 3개 카테고리가 전체 상품의 90이상을 차지하고 그 외에는 상품 수가 매우 적음을 확인하였음.

→ 베스트딜 추천 시스템은 상위 3개 카테고리를 중심으로 제공하기로 결정함. (거래가 활발한 3개 영역 타겟)

-- 1. 카테고리별 상품 수 파악

```
SELECT
  top_category,
  COUNT(DISTINCT product_id) AS product_count
FROM `project-5278bde0-2369-4e6d-8e7.d4.amazon_uj`
GROUP BY top_category
ORDER BY product_count DESC;
```

← 쿼리 결과

작업 정보	결과	시각화	JSON	실행 세부정보	실행 그래프
행	top_category	product_count			
1	Electronics	490			
2	Home&Kitchen	447			
3	Computers&Accessories	373			
4	OfficeProducts	31			
5	MusicalInstruments	2			
6	HomeImprovement	2			
7	Car&Motorbike	1			
8	Health&PersonalCare	1			
9	Toys&Games	1			

(2) EDA 2. 카테고리별 평균 할인율 파악

- 카테고리별 평균 할인율을 보았을 때 40-50 퍼센트 범위가 일반적인 것을 알 수 있었음.

→ 카테고리별 평균이 비슷하고 분산이 크지 않아 '평균보다 높은' 보다는 'Top N' 기준을 택함

-- 2. 카테고리별 평균 할인율 (상품 중복 때문에 일단 유니크 상품으로 걸러줌)

```
WITH unique_products AS (
  SELECT
    product_id,
    ANY_VALUE(top_category) AS top_category,
    ANY_VALUE(discount_percentage) AS discount_percentage
  FROM `project-5278bde0-2369-4e6d-8e7.d4.amazon_uj`
  GROUP BY product_id
)

SELECT
  top_category,
  ROUND(AVG(discount_percentage * 100), 1) AS avg_discount_pct
FROM unique_products
GROUP BY top_category
ORDER BY avg_discount_pct DESC;
```

← 쿼리 결과

작업 정보	결과	시각화	JSON	실행 세부정보	실행 그래프
행	top_category	avg_discount_pct			
1	HomeImprovement	57.5			
2	Computers&Accessories	53.1			
3	Health&PersonalCare	53.0			
4	Electronics	49.9			
5	MusicalInstruments	46.0			
6	Car&Motorbike	42.0			
7	Home&Kitchen	40.2			
8	OfficeProducts	12.4			
9	Toys&Games	0.0			

(3) EDA 3. 타겟 카테고리 리뷰수 통계 확인

- 카테고리별로 리뷰 분포가 극단적으로 다르다는 것을 확인함. (Electronics는 리뷰 상위 30%가 21,796개 이상, Home&Kitchen은 5,476개 이상, Computer&Accessories는 14,039개 이상)

→ 리뷰수에 단일 절대값 기준을 적용하면 특정 카테고리는 대부분 제외되고 어떤 카테고리는 대부분 포함되는 문제가 발생하므로 **본 시스템에서는 카테고리별 상대적 기준인 리뷰 상위 30% 이상을 필터링 기준으로 삼음.**

```
--3. 카테고리별 리뷰수 통계 (평균, 중앙값, 최고값, 70%에 해당된 값-상위 30%에 해당되는 리뷰수가 몇개인지 보려고)
--타겟 3개 카테고리(Electronics, Home&Kitchen, Computers&Accessories)만 대상
WITH unique_products AS (
  SELECT
    product_id,
    ANY_VALUE(top_category) AS top_category,
    ANY_VALUE(rating_count) AS rating_count
  FROM `project-5278bde0-2369-4e6d-8e7.d4.amazon_uj`
  WHERE top_category IN ('Electronics', 'Home&Kitchen', 'Computers&Accessories')
  GROUP BY product_id
),

stats AS (
  SELECT
    top_category,
    COUNT(*) OVER (PARTITION BY top_category) AS product_cnt,
    AVG(rating_count) OVER (PARTITION BY top_category) AS avg_reviews,
    PERCENTILE_CONT(rating_count, 0.5) OVER (PARTITION BY top_category) AS median_reviews,
    PERCENTILE_CONT(rating_count, 0.7) OVER (PARTITION BY top_category) AS p70_reviews,
    MAX(rating_count) OVER (PARTITION BY top_category) AS max_reviews
  FROM unique_products
)

SELECT DISTINCT
  top_category,
  product_cnt,
  avg_reviews,
  median_reviews,
  p70_reviews,
  max_reviews
FROM stats
ORDER BY product_cnt DESC;
```

작업 정보		결과	시각화	JSON	실행 세부정보	실행 그래프
행	top_category	product_cnt	avg_reviews	median_reviews	p70_reviews	max_reviews
1	Electronics	490	28996.77142857...	9129.5	21796.0	426973
2	Home&Kitchen	447	6689.21029082774	2311.0	5476.99999999999	270563
3	Computers&Accessories	373	16984.37533512...	7317.0	14039.99999999...	253105

4. 추천시스템 구현 로직 : SQL

1. 전처리한 테이블에서 product_id 기준으로 묶어 **상품 단위(unique_products)** 생성
2. 카테고리별 리뷰수 70th percentile을 계산 → **리뷰수 상위 30%** 확보
3. 평점 **4.0 이상** & 리뷰수 **review_p70 이상** 상품만 필터링
4. 그 안에서 **할인을 내림차순**으로 정렬하고, 카테고리별 **TOP 10**을 베스트딜로 선정
5. 할인율은 **discount_percentage * 100**으로 변환해 **소수점 1자리 % 단위**로 표시

```
-- 베스트딜 추천 시스템
-- 1) product_id 중복행이 있어서 하나만 반환할 수 있는 ANY_VALUE써서 기준 상품 단위 만들기
WITH unique_products AS (
  SELECT
    product_id,
    ANY_VALUE(product_name) AS product_name,
    ANY_VALUE(top_category) AS top_category,
    ANY_VALUE(discount_percentage) AS discount_percentage,
```

```

    ANY_VALUE(discounted_price) AS discounted_price,
    ANY_VALUE(actual_price) AS actual_price,
    ANY_VALUE(rating) AS rating,
    ANY_VALUE(rating_count) AS rating_count
FROM `project-5278bde0-2369-4e6d-8e7.d4.amazon-uj`
WHERE top_category IN ('Electronics', 'Home&Kitchen', 'Computers&Accessories')
GROUP BY product_id
),

-- 2) 카테고리별 리뷰수 70th percentile (리뷰 상위 30% 기준값)
review_thresholds AS (
  SELECT DISTINCT
    top_category,
    PERCENTILE_CONT(rating_count, 0.7)
      OVER (PARTITION BY top_category) AS review_p70
FROM unique_products
),

-- 3) 품질 필터 적용: 평점 + 리뷰수 기준
base_filtered AS (
  SELECT
    u.*,
    r.review_p70
  FROM unique_products u
  JOIN review_thresholds r USING (top_category)
  WHERE rating BETWEEN 4.0 AND 5.0 -- 평점 필터
    AND rating_count >= review_p70 -- 리뷰 상위 30% 이상
),

-- 4) 할인율 기준 정렬 + 순위 부여
ranked AS (
  SELECT
    *,
    ROUND(discount_percentage * 100, 1) AS discount_pct, -- 소수점 1까지 %표기
    ROW_NUMBER() OVER (
      PARTITION BY top_category
      ORDER BY discount_percentage DESC, rating DESC, rating_count DESC
    ) AS rn
  FROM base_filtered
)

-- 5) 카테고리별 할인율 TOP 10 베스트딜 최종 결과
SELECT
  top_category,
  rn AS rank_in_category,
  product_id,
  product_name,
  discount_pct,
  rating,
  rating_count,
  discounted_price,
  actual_price
FROM ranked
WHERE rn <= 10
ORDER BY top_category, rank_in_category;

```

5. 추천시스템 결과

- 본 추천 시스템은 검증된 인기 제품 중 지금 가장 큰 폭의 할인을 제공하는 상품을 보여주는 것임.
- 그 결과, 상품수가 많이 등록되어 있는 상위 3개 카테고리(Electronics / Home&Kitchen / Computers&Accessories)를 대상으로, 평점 4점 이상 & 리뷰 수 상위 30% 제품에서 할인율 가장 높은 순위별 10개 제품들을 도출함.

- 베스트셀 TOP10 결과를 카테고리별로 비교한 결과, **가장 높은 할인율을 제공하는 카테고리는 Electronics**로 관찰됨. 스마트워치 등 고가 제품군이 상당 포함되어 있으며 **평균 80% 안팎의 높은 할인율**을 보임.
- **Computers&Accessories** 역시 **69~83% 수준의 높은 할인율**을 보이지만 Electronics 대비 평균 할인율은 조금 낮음. USB 케이블 등 저가형 주변기기 제품들이 주로 차지함.
- **Home&Kitchen** 카테고리는 할인율이 상대적으로 낮지만(50~60%), 애그보일러, 워터히터, 믹서기, 조리기구 등 **생활밀착형 제품** 위주로 적당한 할인과 안정된 품질 조합이 특징으로 나타남.

top_category	rank_in_catgo	product_id	product_name	discount_1	rating	rating_count	discount_2	actual_price
Computers&Accessories	1	B08M2Q8FLN	Calfee Multipurpose Foldable Laptop Table with Cup Holder Drawer Mac Holder Table Holder Study Table, Breakfast Table, Foldable and	83	4	20457	840	4999
Computers&Accessories	2	B07K2M74N	STRIFF Adjustable Laptop Tabletop Stand Patented Riser Ventilated Portable Foldable Compatible with MacBook Notebook Tablet Tray De	77	4.5	24791	349	1499
Computers&Accessories	3	B09H111RY7	AmazonBasics USB 2.0 - A Male to 4 Female Extension Cable for Personal Computer, Printer (Black, 9.8 Feet/3 Meters)	73	4.5	74976	199	750
Computers&Accessories	4	B09Y4G5G2Y	Isaki Laptop, Smartphone Type-c A400 Male Data Cable (Carbon Black)	73	4.3	20850	273.1	999
Computers&Accessories	5	B07PFJVGQD	Agento Blaze USB-A to micro - Type C 2011 8 Braided 1.2M Cable	73	4.3	14184	139	595
Computers&Accessories	6	B09H111KX	AmazonBasics USB 2.0 Cable - A Male to B Male - for Personal Computer, Printer - 6 Feet (1.8 Meters), Black	70	4.5	107466	209	695
Computers&Accessories	7	B07Z59HGD	Isaki A400 USB Type-C to USB-A 2.0 Male Data Cable, 2 Meter (Black)	70	4.3	20850	209	999
Computers&Accessories	8	B017P9R9K0	GUZGA Essentials Portable Tablet Stand Mobile Holder, Desktop Stand, Cradle, Dock for iPad, Smartphone, Kindle, E-Reader, Fully F	70	4.1	25607	149	499
Computers&Accessories	9	B027L3M2H0	DAF X0216 Wired Multimedia USB Hub/stand with Super Data Finger Keys with Split Receiver - Black	69	4.3	28829	549	1799
Computers&Accessories	10	B01GGVKNQW	Amazon Basics USB Type-C to USB-A 2.0 Male Fast Charging Cable for Laptop - 3 Feet (0.9 Meters), Black	69	4.3	20052	219	700
Electronics	1	B09YV4630W	Fire-Bolt Nexo 3 Smartwatch Full Touch 1.69" & 4.0 Sports Modes with IP68, SpO2 Tracking, Over 100 Cloud-based watch faces (Silver)	85	4.2	22638	1499	9999
Electronics	2	B07Q4V15L	ELV Aluminum Adjustable Mobile Phone Foldable Tabletop Stand Dock Mount for All Smartphones, Tablets, Kindle, iPad (Black)	82	4.5	26978	289	1499
Electronics	3	B09YV4630Z	Fire-Bolt Nexo 3 Smartwatch Full Touch 1.69" & 4.0 Sports Modes with IP68, SpO2 Tracking, Over 100 Cloud-based watch faces (Green)	81	4.2	22638	1499	9999
Electronics	4	B09YV4630D	Fire-Bolt Nexo 3 Smartwatch Full Touch 1.69" & 4.0 Sports Modes with IP68, SpO2 Tracking, Over 100 Cloud-based watch faces - Black	81	4.2	22638	1499	9999
Electronics	5	B07Q4HCB91	STRIFF PSL21 Multi-Angle Mobile/ Tablet Tabletop Stand- Phone Holder for iPhone, Android, Samsung, OnePlus, Xiaomi, Portable, Foldable	80	4.3	42641	99	499
Electronics	6	B08B999H9F	Fire-Bolt Phoenix Smart Watch with Bluetooth Calling 1.37, 1.20" Sports Modes, 240x240 PX High Res with SpO2, Heart Rate Monitoring & H	80	4.3	27704	1999	9999
Electronics	7	B08B999H9F	Fire-Bolt Phoenix Smart Watch with Bluetooth Calling 1.37, 1.20" Sports Modes, 240x240 PX High Res with SpO2, Heart Rate Monitoring & H	80	4.3	27696	1999	9999
Electronics	8	B08B999H9F	Fire-Bolt Phoenix Smart Watch with Bluetooth Calling 1.37, 1.20" Sports Modes, 240x240 PX High Res with SpO2, Heart Rate Monitoring & H	80	4.3	27696	1999	9999
Electronics	9	B07H4L24B0	STYVO HT 3130 Aluminum Tripod (130CM), Universal Lightweight Tripod with Mobile Phone Holder Mount & Carry Bag for All Smart Phone	80	4.3	27139	799	9990
Electronics	10	B08BZJY8Z	EV Aluminum Adjustable Mobile Phone Foldable Holder Tabletop Stand Dock Mount for All Smartphones, Tablets, Kindle, iPad (Moonlight Bl	79	4.5	26978	314	1499
Home&Kitchen	1	B07H0WDC4X	Smeets Egg Boiler Electric Automatic Off 7 Eggs Poacher for Steaming, Cooking Also Boiling and Frying 400 W (Blue, Pink)	65	4	15646	349	999
Home&Kitchen	2	B01BRKFX92	Health Blue Leaf Diamond MG-214 mixer grinder 750 watt (Blue/White), 3 jars & Flexi Lid, FBT motor with 2-yr Guarantee & Lifetime Free Se	62	4.1	11828	3999	9435
Home&Kitchen	3	B01W9G5237	Pigeon Polypropylene Mix-Handy and Compact Chopper with 3 Blades for Effortlessly Chopping Vegetables and Fruits for Your Kitchen (C	60	4.1	270563	199	495
Home&Kitchen	4	B08L34CB88	Kuber Industries Waterproof Canvas Laundry Bag/Hampers(Metalic-Printed With Handles)Foldable Bin & 45 Liter CapacitySize 37" x 37" x 46.1	60	4	10234	199	499
Home&Kitchen	5	B097XJQ28H	Cookwell Bullet Mixer Grinder (3-Jars, 3 Blades, Silver)	59	4.1	8866	2464	6000
Home&Kitchen	6	B097H689H8	Bajaj New Shakti Neo 150 Vertical Storage Water Heater (Dipper 15 litres) 4 Star BEE Rated Heater For Water Heating with Titanium Anodo	58	4.2	4396	3499	10150
Home&Kitchen	7	B097C2V1W8	Bajaj Splendora 3-Litre 30W 90W Instant Water Heater (Daynet), White	56	4.1	21783	3999	5890
Home&Kitchen	8	B07QSSX9V6	INALSA Electric Kettle 1.5 Litre with Stainless Steel Body - AbsAuto Shut Off & Roll Dry Protection Safety Features Cordless Base & Cord	56	4.1	8090	699	1595
Home&Kitchen	9	B01C8PZ9N0	Bajaj D4-6 1000W Dry Iron with Advance Solplate and Anti-bacterial German Coating Technology, White	55	4.2	23516	625	1400
Home&Kitchen	10	B08BZJY8Z	Compton Sprayer 0.5 L Instant Water Heater (Daynet)	51	4	10234	3999	7299

추천 시스템 2. 숨겨진 진주 (Hidden Gems) 추천 시스템

1. 추천 시스템 이름

숨겨진 진주(Hidden Gems) 추천 시스템

2. 추천 시스템 테마/컨셉

본 시스템은 리뷰 개수는 적지만 실제로 구매한 사람들의 만족도가 압도적으로 높은 제품을 찾아 추천하는 시스템임.

→ 즉, 아직 알려지지 않았으나(소규모 리뷰 기반) 긍정 표현과 평점이 압도적으로 높은 제품만 선별해 소비자들에게 안전하면서도 새로운 제품 발견 경험을 제공하는 것이 목표임.

히든젬 조건은 아래 3가지를 모두 충족하는 것으로 기준을 정하였음.

- 평점 ≥ 4.5
- $5 \leq$ 리뷰 수 ≤ 1000
- 리뷰텍스트 기반 긍정키워드 ≥ 1 회 등장 AND 부정키워드 0회 등장

3. 구현 로직 배경 : EDA를 통한 인사이트 도출

(1) EDA 1. 리뷰 수 분포 확인

- 리뷰수 분포를 10분위수 기준으로 분석한 결과 하위 20% 구간이 리뷰 수 766, 30%가 1662로 나타남.

→ 리뷰가 없거나 너무 적으면 품질 판단이 어려워 최소 5인 이상의 리뷰가 있고 1000이하개가 있는 상품을 '리뷰가 적은 상품'으로 정의함.

```
-- 리뷰수 분포 EDA (1%, 10%, 20%, 30%... 10분위 단위로 개수 파악)
SELECT
  APPROX_QUANTILES(rating_count, 10) AS rating_count_deciles
FROM `project-5278bde0-2369-4e6d-8e7d.d4.amazon_uf`;
```

작업 정보	결과	시각화
행	rating_count_deciles	
1	2	
	252	
	766	
	1662	
	2960	
	5178	
	8751	
	13937	
	21764	
	38879	
	426973	

- 평점 4.5 이상 & 리뷰수 1000이하를 동시에 만족하는 상품 30개로 파악됨

- 히든젼 후보군으로 활용하기에 적절한 규모로 생각됨.

- 실제 상품 목록도 확인한 결과, 리뷰 타이틀과 리뷰 콘텐츠에 주로 어떤 긍정적인 단어들이 있는지 살펴봄

--리뷰수 적으면서 평점 높은 후보 제품들이 대략 몇개 확보되는지 개수 확인

```
SELECT
  COUNT(*) AS hidden_candidate_count
FROM `project-5278bde0-2369-4e6d-8e7.d4.amazon_uj`
WHERE rating >= 4.5
  AND rating_count BETWEEN 5 AND 1000;
```

--실제 목록 확인

```
SELECT
    product_id,
    product_name,
    top_category,
    rating,
    rating_count,
    review_title,
    review_content
FROM `project-5278bde0-2369-4e6d-8e7.d4.amazon_uj`
WHERE rating >= 4.5
    AND rating_count BETWEEN 5 AND 1000
ORDER BY rating_count ASC
LIMIT 50;
```

[illegible]

- 1번 시스템 EDA 했던 결과의 **상품수가 많고 리뷰수가 많았던 상위카테고리 3개 안에서 히든젼 후보 상품이 나오는 것을 확인함**

- Computers&Accessories 12개, Home&Kitchen 11개, Electronics 7개의 히든잼이 관찰됨.

--히든젼 후보 카테고리 분포 확인
WITH candidates AS (

```

SELECT
  product_id,
  top_category
FROM `project-5278bde0-2369-4e6d-8e7.d4.amazon_uj`
WHERE rating >= 4.5
      AND rating_count BETWEEN 5 AND 1000
)
SELECT
  top_category,
  COUNT(*) AS product_count
FROM candidates
GROUP BY top_category
ORDER BY product_count DESC;

```

작업 정보	결과	시각화	JSON	실행 세부정보	실행 그래프
행	top_category ▼		product_count ▼		
1	Computers&Accessories		12		
2	Home&Kitchen		11		
3	Electronics		7		

4. 추천 시스템 구현 로직 : SQL

조건

- 평점 rating >= 4.5
- 리뷰 수 $5 \leq \text{rating_count} \leq 1000$
- 긍정 키워드(good, amazing, like, perfect, trust, fine, awesome) 중 하나 이상 포함
- 부정 키워드(bad, poor, broken, not good, not working, disappointed)는 포함되지 않음
- 단어 경계(\b)를 써서 "goodbye" 같은 건 매칭 안 되게 함

구현

1. 상품별로 리뷰 텍스트(review_title과 review_content)를 모두 합친것을 만들기
2. 긍정/부정 키워드 포함 유무는 정규표현식으로 탐지하여
3. 평점(4.5점 이상), 리뷰수 (5-1000사이), 텍스트 감성(긍정 표현은 존재하나 부정표현은 0임)을 동시에 만족하는 상품 필터링
4. $\text{gem_score} = \text{rating} + \text{positive_hit_count} * 0.3$ 으로 점수를 계산하여 상위 10개 히트템을 추천함. (→ rating 이 주된 점수와 4.5 - 5점대, 보조 지표 점수가 1.5점 내외에서 더해질 수 있도록 최대 카운트될 수 있는 단어의 수를 약 5개 정도로 추정하여 가중치 0.3으로 잡음)

```

-- 1단계: 상품별로 리뷰 텍스트를 통합한 기초 테이블 생성
WITH base AS (
  SELECT
    product_id,
    -- 같은 product_id 안에서 대표 product_name 하나만 사용
    ANY_VALUE(product_name) AS product_name,
    ANY_VALUE(top_category) AS top_category,
    ANY_VALUE(rating) AS rating,
    ANY_VALUE(rating_count) AS rating_count,
    -- 리뷰 제목 + 리뷰 내용을 모두 합쳐서 하나의 텍스트(full_text)로 생성
    LOWER(
      CONCAT(
        STRING_AGG(COALESCE(review_title, ''), ' '),
        ' ',
        STRING_AGG(COALESCE(review_content, ''), ' ')
      )
    ) AS full_text
  FROM `project-5278bde0-2369-4e6d-8e7.d4.amazon_uj`
  GROUP BY product_id
),

-- 2단계: 긍정/부정 키워드 탐지 및 긍정 키워드 종류 수 계산
scored AS (
  SELECT

```



```

product_id,
product_name,
top_category,
rating,
rating_count,

-- 부정 키워드가 하나라도 포함되어 있는지 여부
REGEXP_CONTAINS(
    full_text,
    r'(bad|poor|broken|not good|not working|disappointed)'
) AS has_negative_word,

-- 긍정 키워드가 텍스트에 등장하는지 (등장한 단어 종류 수 합계)
(
    CASE WHEN REGEXP_CONTAINS(full_text, r'\bgood\b') THEN 1 ELSE 0 END +
    CASE WHEN REGEXP_CONTAINS(full_text, r'\bexcellent\b') THEN 1 ELSE 0 END +
    CASE WHEN REGEXP_CONTAINS(full_text, r'\bnice\b') THEN 1 ELSE 0 END +
    CASE WHEN REGEXP_CONTAINS(full_text, r'\bbest\b') THEN 1 ELSE 0 END +
    CASE WHEN REGEXP_CONTAINS(full_text, r'\bgreat\b') THEN 1 ELSE 0 END +
    CASE WHEN REGEXP_CONTAINS(full_text, r'\btrust\b') THEN 1 ELSE 0 END +
    CASE WHEN REGEXP_CONTAINS(full_text, r'\bfine\b') THEN 1 ELSE 0 END +
    CASE WHEN REGEXP_CONTAINS(full_text, r'\bawesome\b') THEN 1 ELSE 0 END +
    CASE WHEN REGEXP_CONTAINS(full_text, r'\blove\b') THEN 1 ELSE 0 END +
    CASE WHEN REGEXP_CONTAINS(full_text, r'\blike\b') THEN 1 ELSE 0 END
) AS positive_hit_count
FROM base
)

-- 3단계: 히트맵 조건 필터링 및 점수 산출
SELECT
    product_id,
    product_name,
    top_category,
    rating,
    rating_count,
    positive_hit_count,
    -- 히트맵 점수 = 평점 + (긍정 키워드 종류 수 * 0.3)
    ROUND(rating + positive_hit_count * 0.3, 3) AS gem_score
FROM scored
WHERE
    -- 만족도가 충분히 높은 상품만 사용
    rating >= 4.5
    -- 리뷰는 너무 적지도(5 미만) 너무 많지도(1000 초과) 않은 구간
    AND rating_count BETWEEN 5 AND 1000
    -- 긍정 키워드는 하나 이상 등장
    AND positive_hit_count > 0
    -- 부정 키워드는 단 한 번도 등장하지 않음
    AND has_negative_word = FALSE
ORDER BY gem_score DESC
LIMIT 10;

```

5. 추천시스템 결과

T1	T1	T1	103	103	103	103
product_id	product_name	top_category	rating	rating_count	positive_hit_count	gem_score
B08LC2BYPK	Zureva USB Rechargeable Electric Foam Maker - Handheld Milk Wand Mixer Frother for Hot Milk, Hand Blend	Home&Kitchen	4.7	54	6	6.5
B0829K23Y1	Dashish Coffee Frother electric, milk frother electric, coffee beater, cappuccino maker, Coffee Foamer, Mocha	Home&Kitchen	4.8	28	5	6.3
B0844F9QJ2	Gadgetspro Digital Kitchen Weighing Scale & Food Weight Machine for Health, Fitness, Home Baking & Cook	Home&Kitchen	4.5	63	6	6.3
B09P1MFKG1	Melbore VM-905 2000-Watt Room Heater (30 Certified, White Color) Ideal Electric Fan Heater for Small to Medi	Home&Kitchen	4.4	9	5	6.1
B08H8XK8C7	Wecool 55 Long Saffle Stick, with Large Reinforced Tripod Stand up to 61 inch / 156 Cms, Ultra Long Multi Fun	Electronics	4.6	245	5	6.1
B08J9M4K8K	Acropolis Copper - Mineral Ionic(VolP) 10 to 12 Liter 800 x 100 x 100-150-60-60-60 Water Purifier with Copper	Home&Kitchen	4.4	124	5	6.1
B084N18C2V	Belkin USB-C to USB-C Fast Charging Type-C Cable, 60W PD, 3.3 feet (1 meter) for Laptop, Personal Comput	Computers&Accessories	4.5	577	5	6
B07C9H2FC1	Duracell USB Lightning Apple Certified (MFi) Braided Sync & Charge Cable for iPhone, iPad And And. 1 feet Cha	Computers&Accessories	4.5	815	5	6
B08MKNJ3M6	Laptop USB compatible for OnePlus 6/7 Pro/8 Pro/8 Pro/8 Pro/8 Pro/8 Pro/8 Pro/8 Pro/8 Pro/8 Pro/8 Pro/8 Pro	Computers&Accessories	4.5	127	5	6
B08C9W37WV	Homeotic Appliance™ Instant Electric Water Heater Faucet Tap For Kitchen And Bathroom Sink Digital Water	Home&Kitchen	4.5	19	5	6


- 히트맵 추천 시스템으로 도출된 10개 상품은 평점이 4.5점 이상으로 매우 높지만 리뷰 수는 상대적으로 적고, 리뷰 텍스트에서 긍정 표현이 풍부하게 등장하여 부정 감성이 없는 기준을 충족하는 제품으로 구성되어 있음.
- 추천 상품들은 주로 Home&Kitchen과 Computers&Accessories 카테고리에 분포함.

- 히든젼 대표 사례로 1등을 차지한 제품은

Zuveza USB Rechargeable Electric Foam Maker (gem_score = 6.5)임. 해당 데이터의 수집 시기는 정확하게 나와있지 않으나, 3년 전 업데이트된 것으로 파악됨.

→ 현재 아마존 사이트에 들어가서 살펴 보았더니 해당 제품은 그 사이 평점이 4.4점, 리뷰수는 843개, 그리고 최근 많이 팔린 "Amazon's Choice"제품 중 하나라는 표시가 확인되었음.

[제품 정보, Ref. https://www.amazon.in/Zuvexa-Rechargeable-Handheld-Milk-Frother/dp/B0C6K7TQWY/ref=pd_lpo_d_scc1_2/520-4036875-9795616?pd_rd_w=KVQHP&content-id=amzn1.sym.e0c8139c-1aa1-443c-af8a-145a0481f27c&pf_rd_p=e0c8139c-1aa1-443c-af8a-145a0481f27c&pf_rd_r=TKKTGBWMWET2QGZHQCZ3&pd_rd_wg=UXBho&pd_rd_r=53ab44b7-1dd9-4686-bf93-6b2c2c049300&pd_rd_i=B0C6K7TQWY&th=1]



- 즉, 3년 전 데이터로 히든젼 제품을 추천하였는데, 시간이 지난 후 높은 판매량을 기록하고 있는 제품으로 성장한 것을 확인한 셈임. → 이는 본 시스템이 리뷰 수가 적을 때부터 잠재력이 높은 제품을 조기에 탐지해낼 수 있었음을 시사하며, 히든젼 추천 알고리즘이 실제 사용자 수요와 시장 반응을 상당 부분 예측한 사례라고 생각해 볼 수 있음.

추천 시스템 3. 예산대별 선물하기 좋은 상품 추천 시스템

1. 추천 시스템 이름

예산대별 선물하기 좋은 상품 추천 시스템

2. 추천 시스템 테마/컨셉

고객이 선물을 살 때 가장 먼저 고려하는 것은 예산임.

따라서 고객이 예상하는 예산에서 품질이 어느 정도 검증된 선물용 제품을 찾을 때 유용하게 활용할 수 있는 시스템을 도출하고자 함.

본 설계시 고려한 조건은 아래와 같음.

- 선물 목적이 명확하게 드러나는 상품 식별 : 상품명, 설명, 리뷰 텍스트에 선물 암시 키워드 포함
- 품질 필터 적용 : 평점 4.0 이상/ 리뷰수 50개 이상
- 가격대별 그룹핑

즉, 해당 추천 시스템은 상품 설명과 리뷰에서 '선물용'이라는 것을 암시하는 단어를 포함하고, 충분한 리뷰와 평점을 확보한 검증된 상품 중 예산대별 추천 가능한 선물용 상품을 제시하는 것을 목표로 함.

3. 구현 로직 배경 : EDA를 통한 인사이트 도출

(1) EDA 1. 상품명+설명+리뷰 타이틀/본문을 하나로 묶어서 text_sample 만든 후, 그 중 선물용 키워드를 포함한 후보 제품들이 몇개 정도 있는지 확인

- 전체 1348개의 제품 중 선물 관련 암시 단어가 포함된 제품은 총 102개임

→ 전체의 약 7.6% 정도가 선물용 제품이라는 것을 암시하는 정보를 포함하고 있고, 리뷰수와 평점으로 필터링 하기에 너무 적지 않은 규모여서 적당하다고 판단됨.

```
1-1. 일단 텍스트 묶어서 하나로 잘 나오는지 확인
WITH base_text AS (
  SELECT
```

```

product_id,

-- product_id별 대표 기본 속성 (중복 행이 존재하므로 ANY_VALUE 사용)
ANY_VALUE(product_name) AS product_name,
ANY_VALUE(top_category) AS top_category,
ANY_VALUE(rating) AS rating,
ANY_VALUE(rating_count) AS rating_count,
ANY_VALUE(discount_percentage) AS discount_percentage,
ANY_VALUE(discounted_price) AS discounted_price,
ANY_VALUE(actual_price) AS actual_price,

-- 상품 텍스트 통합
LOWER(
  CONCAT(
    ANY_VALUE(product_name), ' ',
    COALESCE(ANY_VALUE(about_product), ''), ' ',
    STRING_AGG(COALESCE(review_title, ''), ' '), ' ',
    STRING_AGG(COALESCE(review_content, ''), ' ')
  )
) AS text_all

FROM `project-5278bde0-2369-4e6d-8e7.d4.amazon_uj`
GROUP BY product_id -- ← 여기엔 세미콜론(;) 넣지 말기
)

-- CTE(base_text) 결과를 실제로 조회하는 메인 쿼리
SELECT
  product_id,
  product_name,
  SUBSTR(text_all, 1, 300) AS text_sample
FROM base_text
LIMIT 10;

1-2. 전체 상품 수 대비 실제 선물 관련 키워드 포함 상품 수 파악해보기
WITH base_text AS (
  SELECT
    product_id,
    ANY_VALUE(product_name) AS product_name,
    ANY_VALUE(top_category) AS top_category,
    ANY_VALUE(rating) AS rating,
    ANY_VALUE(rating_count) AS rating_count,
    ANY_VALUE(discount_percentage) AS discount_percentage,
    ANY_VALUE(discounted_price) AS discounted_price,
    ANY_VALUE(actual_price) AS actual_price,

    -- 상품명 + 설명 + 리뷰 텍스트를 하나로 합침
    LOWER(
      CONCAT(
        ANY_VALUE(product_name), ' ',
        COALESCE(ANY_VALUE(about_product), ''), ' ',
        STRING_AGG(COALESCE(review_title, ''), ' '), ' ',
        STRING_AGG(COALESCE(review_content, ''), ' ')
      )
    ) AS text_all
  FROM `project-5278bde0-2369-4e6d-8e7.d4.amazon_uj`
  GROUP BY product_id
)

SELECT
  COUNT(*) AS total_products, -- 전체 상품 수
  COUNTIF(
    REGEXP_CONTAINS(
      text_all,
      r'(gift|present|birthday|anniversary|christmas|wedding|valentine)'
    )
  )

```

```
)
) AS gift_keyword_products -- 선물 관련 키워드 포함 상품 수
FROM base_text;
```

← 쿼리 결과

작업 정보	결과	시각화	JSON	실행 세부정보	실행 그래프
행	total_products	gift_keyword_pro...			
1	1348	102			

(2) EDA 2. 선물 키워드 포함 + 평점(4.0 이상) + 리뷰수 (50 이상)으로 필터링 함.

- 실제 선물로 추천해도 될만한 품질을 가진 상품으로 필터링하는 쿼리문을 돌렸더니 70개로 추려짐.

→ 이것을 카테고리별로 보여주는 게 좋을지 가격대별로 보여주는 게 좋을지 일단 분포 확인이 필요하다고 판단함.

```
WITH base_text AS (
  SELECT
    product_id,
    ANY_VALUE(product_name) AS product_name,
    ANY_VALUE(top_category) AS top_category,
    ANY_VALUE(rating) AS rating,
    ANY_VALUE(rating_count) AS rating_count,
    ANY_VALUE(discount_percentage) AS discount_percentage,
    ANY_VALUE(discounted_price) AS discounted_price,
    ANY_VALUE(actual_price) AS actual_price,

    LOWER(
      CONCAT(
        ANY_VALUE(product_name), ' ',
        COALESCE(ANY_VALUE(about_product), ''), ' ',
        STRING_AGG(COALESCE(review_title, ''), ' '), ' ',
        STRING_AGG(COALESCE(review_content, ''), ' ')
      )
    ) AS text_all
  ) AS text_all

FROM `project-5278bde0-2369-4e6d-8e7.d4.amazon_uj`
GROUP BY product_id
),
-- 평점과, 리뷰수 조건 걸어주기
candidates AS (
  SELECT *
  FROM base_text
  WHERE rating >= 4.0
  AND rating_count >= 50
  AND REGEXP_CONTAINS(
    text_all,
    r'(gift|present|birthday|anniversary|christmas|wedding|valentine)'
  )
)

SELECT
  COUNT(*) AS refined_candidate_count
FROM candidates;
```

작업 정보	결과	시각화
행	refined_candidate...	
1	70	

(3) EDA 3. 70개 후보의 카테고리별 개수 확인

- 70개의 선물 후보를 카테고리별로 분석한 결과, **Electronics** 카테고리가 전체의 절반에 가까운 32개로 가장 많은 비중을 차지하고 그 다음으로는 **Home&Kitchen (19개)**, **Computers&Accessories (13개)**, **OfficeProducts (6개)** 순임.

```
WITH base_text AS (
  SELECT
    product_id,
    ANY_VALUE(product_name) AS product_name,
    ANY_VALUE(top_category) AS top_category,
    ANY_VALUE(rating) AS rating,
    ANY_VALUE(rating_count) AS rating_count,
    ANY_VALUE(discount_percentage) AS discount_percentage,
    ANY_VALUE(discounted_price) AS discounted_price,
    ANY_VALUE(actual_price) AS actual_price,
    LOWER(
      CONCAT(
        ANY_VALUE(product_name), ' ',
        COALESCE(ANY_VALUE(about_product), ''), ' ',
        STRING_AGG(COALESCE(review_title, ''), ' '), ' ',
        STRING_AGG(COALESCE(review_content, ''), ' ')
      )
    ) AS text_all
  FROM `project-5278bde0-2369-4e6d-8e7.d4.amazon_uj`
  GROUP BY product_id
),

candidates AS (
  SELECT
    *,
    ROUND(discount_percentage * 100, 1) AS discount_pct
  FROM base_text
  WHERE rating >= 4.0
    AND rating_count >= 50
    AND REGEXP_CONTAINS(
      text_all,
      r'(gift|present|birthday|anniversary|christmas|wedding|valentine)'
    )
)
-- 카테고리별로 그룹핑해서 보기
SELECT
  top_category,
  COUNT(*) AS product_count
FROM candidates
GROUP BY top_category
ORDER BY product_count DESC;
```

작업 정보	결과	시각화	JSON	실행 세부정보	실행 그래프
행	top_category ▼	product_count ▼			
1	Electronics	32			
2	Home&Kitchen	19			
3	Computers&Accessories	13			
4	OfficeProducts	6			

(4) EDA 4. 70개 후보의 가격대별 (실용 예산대 1500이하, 5000이하 중간 가격대, 5001 이상 고가 선물)

- 처음에 가격 분포를 보고 4개 구간을 생각했다가 3개로 단순화시킴.
- 사용자 입장에서 예산 수준별로 선물 후보를 직관적으로 탐색할 수 있도록 설계함.
- 500루피 이하**는 케이블, 작은 주변기기 등 소액 **충동구매/부담 없는 선물**이 주로 포함되기 때문에, 500-1500 구간과 함께 하나의 "Affordable Gift(≤1500)"로 묶음
- 1501-5000 루피 구간**은 에어프라이어, 히터, 고급 주방기기 등 **집에서 오래 사용하는 실용적인 제품**이 많아 "Premium Practical" 가격대로 정의함
- 5001 루피 이상**은 스마트워치, 고가 가전, 고급 오피스 장비 등 **기념일/특별한 날용 고가 선물**이 주로 속해 "High-end Gift"로 분리함.

- 그 결과 실용적 저예산 선물 42개, 실용적 프리미엄 선물 12개, 고급 선물 16개가 분포함을 확인함.

→ 선물 추천 시스템은 각 가격대에서의 품질과 할인율 고려하여 대표 제품을 추천(상품 수 비율 고려하여 Affordable Gift TOP10, Premium Practical TOP 5, High-End Gift TOP5)하는 것으로 결정하였음.

```
WITH base_text AS (
  SELECT
    product_id,
    ANY_VALUE(product_name) AS product_name,
    ANY_VALUE(top_category) AS top_category,
    ANY_VALUE(rating) AS rating,
    ANY_VALUE(rating_count) AS rating_count,
    ANY_VALUE(discount_percentage) AS discount_percentage,
    ANY_VALUE(discounted_price) AS discounted_price,
    ANY_VALUE(actual_price) AS actual_price,
    LOWER(
      CONCAT(
        ANY_VALUE(product_name), ' ',
        COALESCE(ANY_VALUE(about_product), ''), ' ',
        STRING_AGG(COALESCE(review_title, ''), ' '), ' ',
        STRING_AGG(COALESCE(review_content, ''), ' ')
      )
    ) AS text_all
  FROM `project-5278bde0-2369-4e6d-8e7.d4.amazon_uj`
  GROUP BY product_id
),

--가격대 범위 조건 지정
candidates AS (
  SELECT
    *,
    CASE
      WHEN discounted_price <= 1500 THEN 'Affordable Gift'
      WHEN discounted_price BETWEEN 1501 AND 5000 THEN 'Premium Practical'
      ELSE 'High-end Gift'
    END AS price_band
  FROM base_text
  WHERE rating >= 4.0
    AND rating_count >= 50
    AND REGEXP_CONTAINS(
      text_all,
      r'(gift|present|birthday|anniversary|christmas|wedding|valentine)'
    )
)

-- 가격대별 개수 확인
SELECT
  price_band,
  COUNT(*) AS product_count
FROM candidates
GROUP BY price_band
ORDER BY product_count DESC;
```

작업 정보	결과	시각화	JSON	실행 세부정보	실행 그
행	price_band ▼		product_count ▼		
1	Affordable Gift		42		
2	High-end Gift		16		
3	Premium Practical		12		

4. 추천 시스템 구현 로직 : SQL

1. 상품 텍스트 통합하여 선물 관련 키워드를 상품 단위에서 검색할 수 있도록 전처리

- CONCAT + STRING_AGG 를 사용하여 상품명 + 상품설명 + 리뷰 제목 + 리뷰 내용을 하나의 문자열 text_all로 통합함.

2. 선물 후보 제품 필터링 (텍스트 + 품질 기준)

- text_all 안에 선물 맥락을 암시하는 키워드(*gift, present, birthday, anniversary, christmas, wedding, valentine*) 가 1개 이상 포함되고,
- 평점 rating ≥ 4.0 , 리뷰 수 rating_count ≥ 50 을 동시에 만족하는 제품만 선별하여 선물 후보군 생성

3. 가격대 밴드(3단계) 생성

- 할인 적용 가격(discounted_price) 기준으로 CASE문을 사용해 가격대를 3개 밴드로 구분함.
 - Affordable Gift : $\leq 1,500$
 - Premium Practical : $1,501 \sim 5,000$
 - High-end Gift : $\geq 5,001$

4. 가격대별 랭킹 산출 (ROW_NUMBER 사용)

- 각 가격대(price_band) 안에서 평점(rating) → 리뷰수(rating_count) → 할인율(discount_percentage) 내림차순으로 정렬하고,
- ROW_NUMBER() OVER (PARTITION BY price_band ORDER BY ...) 를 사용해
가격대별 제품 순위를(rank_in_band) 1, 2, 3... 형태로 부여함.

5. 최종 추천 리스트 추출

- 랭킹 결과에서 **Affordable Gift**: 상위 10개, **Premium Practical**: 상위 5개, **High-end Gift**: 상위 5개를 각각 선택하여, 총 20개의 “예산 기반 선물 추천 리스트”를 최종 추천 결과로 제시함.

```
-- [추천 시스템 3] 가격대 기반 선물 추천 시스템

-- STEP 1. 상품 + 설명 + 리뷰 텍스트 통합
WITH base_text AS (
  SELECT
    product_id,
    ANY_VALUE(product_name) AS product_name,
    ANY_VALUE(top_category) AS top_category,
    ANY_VALUE(rating) AS rating,
    ANY_VALUE(rating_count) AS rating_count,
    ANY_VALUE(discount_percentage) AS discount_percentage,
    ANY_VALUE(discounted_price) AS discounted_price,
    ANY_VALUE(actual_price) AS actual_price,

    -- 전체 텍스트를 하나로 합침
    LOWER(
      CONCAT(
        ANY_VALUE(product_name), ' ',
        COALESCE(ANY_VALUE(about_product), ''), ' ',
        STRING_AGG(COALESCE(review_title, ''), ' '), ' ',
        STRING_AGG(COALESCE(review_content, ''), ' ')
      )
    ) AS text_all

  FROM `project-5278bde0-2369-4e6d-8e7.d4.amazon_uj`
  GROUP BY product_id
),

-- STEP 2. 선물 키워드 + 평점·리뷰 필터링
candidates AS (
  SELECT
    *,
    ROUND(discount_percentage * 100, 1) AS discount_pct,

    CASE
      WHEN discounted_price <= 1500 THEN 'Affordable Gift'
      WHEN discounted_price BETWEEN 1501 AND 5000 THEN 'Premium Practical'
      ELSE 'High-end Gift'
    END AS price_band

  FROM base_text
  WHERE rating >= 4.0
```

```

AND rating_count >= 50
AND REGEXP_CONTAINS(
  text_all,
  r'(gift|present|birthday|anniversary|christmas|wedding|valentine)'
)
),

-- STEP 3. 가격대별 평점·리뷰수·할인율 기반 랭킹 산출
ranked AS (
  SELECT
    *,
    ROW_NUMBER() OVER (
      PARTITION BY price_band
      ORDER BY rating DESC, rating_count DESC, discount_percentage DESC
    ) AS rank_in_band
  FROM candidates
)

```

-- STEP 4. 가격대별 최종 추천 (Affordable 10개, 나머지 5개씩)

```

SELECT
  price_band,
  rank_in_band,
  product_id,
  product_name,
  rating,
  rating_count,
  discount_pct,
  discounted_price,
  actual_price
FROM ranked
WHERE
  (price_band = 'Affordable Gift' AND rank_in_band <= 10) OR
  (price_band = 'Premium Practical' AND rank_in_band <= 5) OR
  (price_band = 'High-end Gift' AND rank_in_band <= 5)
ORDER BY price_band, rank_in_band;

```

5. 추천시스템 결과

Tb	123	Tb	Tb	123	123	123	123	123
price_band	rank_in_b	product_id	product_name	rating	rating_coc	discount_1	discounte	actual_pri
Affordable Gift	1	B0DLZDQ24	Classmate Soft Cover 6 Subject Spiral Binding Notebook, Single Line, 300 Pages	4.5	8618	2	157	160
Affordable Gift	2	B08WQCFQF	Carv JET French Press Coffee and Tea Maker 600ml with 4 Level Filtration System, Heat Resistant Borosilicate	4.5	1065	27	1099	1500
Affordable Gift	3	B0DLXTFMRS	PIDILITE Fevoryl Acrylic Colours Sunflower Kit (10 Colors x 15 ml) DIY Paint, Rich Pigment, Non-Cracking Paint	4.4	7203	15	191	225
Affordable Gift	4	B0RMZWNZSV	INOVERA World Map Extended Anti Slip Rubber Gaming Stitched Mouse Pad Desk Mat for Computer Laptop 8	4.4	1695	50	499	999
Affordable Gift	5	B05SFNAC8	FABRISAT Lint Remover for Clothes - Sticky Lint Roller for Clothes, Furniture, Wool, Coat, Car Seats, Carpet, Fat	4.4	290	40	248	499
Affordable Gift	6	B08ZM9RVV	Zoveva Egg Roller Poacher Automatic Off Steaming, Cooking, Boiling Double Layer 14 Egg Roller (Multicolor)...	4.4	227	58	419	999
Affordable Gift	7	B08HVL8QNZ	Mi 10000mAh Li-Polymer, Micro-USB and Type C Input Port, Power Bank 3i with 18W Fast Charging (Midnight)	4.3	178912	48	1149	2199
Affordable Gift	8	B09BK3H9Z2	TP-Link USB Bluetooth Adapter for PC, 5.0 Bluetooth Dongle Receiver (UB500) Supports Windows 11/10/8/1/7	4.3	95116	33	599	899
Affordable Gift	9	B0D3L6T7W	Lugitech B110 Wired USB Mouse, 3-y Warning, 800 DPI Optical Tracking, Ambidextrous PC/Mac Laptop - Bla	4.3	31534	26	279	375
Affordable Gift	10	B07YL54NVJ	Brand Conquer 6 in 1 with OTG, SD Card Reader, USB Type C, USB 3.0 and Micro USB, for Memory Card (Portal	4.3	7758	45	549	999
High-end Gift	1	B09XXZQ2C1	Xiaomi Pad 5i Qualcomm Snapdragon 860 120Hz Refresh Rate 6GB, 128GB 2.5K+ Display (10.95-inch/27.81	4.6	2886	29	26999	37999
High-end Gift	2	B08NPR65K	INALSA Air Fryer Digital 4L Nutri Fry - 1400W with Smart AirCrisp Technology(8-Preset Menu, Touch Control &	4.5	3192	38	6790	10995
High-end Gift	3	B07867WHTT	AGARO Imperial 240-Watt Slow Juicer with Cold Press Technology	4.4	2266	47	12629	22999
High-end Gift	4	B0SLPQDQ2C	Mi 10S 5G (4G inches) (Midnight) (8GB/128GB) (Black)	4.3	27151	63	19999	34999
High-end Gift	5	B081YVCJ2Y	Acer 80 cm (32 inches) Series HD Ready Android Smart LED TV AR32AR2841HDF1 (Black)	4.3	4703	42	11499	19990
Premium Practical	1	B089B2ZYL4	KINGONE Wireless Charging Pencil (2nd Generation) for iPad with Magnetic and Tilt Sensitive, Palm Rejection,	4.5	1526	63	2599	6999
Premium Practical	2	B09LQD7N2Q	Realme Smart TV Stick 4K	4.5	224	0	4699	4699
Premium Practical	3	B07KJ4TWS	Brylgen Chops, Electric Vegetable Chopper for Kitchen with 500 ML Capacity, 400 Watts Copper Motor and 4	4.4	1558	20	1599	1999
Premium Practical	4	B08P18W8TM	Fire-Bolt Gladiator 1.96" Biggest Display Smart Watch with Bluetooth Calling, Voice Assistant & 123 Sports Mo	4.4	73	60	3999	9999
Premium Practical	5	B08QTKX7Q	Philips GC1905 1440-Watt Steam Iron with Spray (Blue)	4.3	37974	8	1614	1745

- 본 시스템은 실제 소비자가 선물을 선택할 때 고려하는 가격대 기준으로 상품을 분류하고, 그 안에서 평점, 리뷰 수, 할인율을 기준으로 품질 신뢰도가 검증된 Top 상품들을 추천함.

→ 즉, 단순 가격 기반 추천이 아닌 사용자 리뷰기반 품질 검증 + 선물 키워드 분석 + 가격대별 선호도 반영이라는 3가지 요소를 결합하여 실용적이고 신뢰성 높은 추천을 제공하는 “맞춤형 선물 큐레이션 시스템”임.

Affordable Gift → 부담없이 일상적으로 직장/지인용 선물로 적합한 실용적·저예산 중심 선물 (예. 실생활 활용도 높은 문구류, 주방/생활 용품 등)

High-End Gift → 가성비보다는 좀 더 특별한 선물을 찾는 소비자들을 위한 품질/브랜드 우선의 고급 실용 선물 (예. 키보드 케이스, 소형 가전과 TV 등의 제품들이 포함)

Premium Practical → 특별한 날 오래 사용할 수 있는 기념일·특별 선물용 프리미엄 제품 (예. 프리미엄 소형 가전, 스마트워치 및 스마트 TV 포함)

- 최종적으로 필터링된 후보 70개 제품을 가격대별로 분류한 결과 총 **42개(저렴한 실용 선물), 16개(고급 선물), 12개(프리미엄 실용 선물)**로 나뉘었으며, 각 가격대에서 가장 추천할 만한 Top 상품 도출함

→ 데이터셋에 가격에 대한 화폐 단위가 포함되어 있지 않아 정확한 가격을 추산하긴 어려웠으나 상품들 종류를 보고 대략 예산 범위가 저가인지 중고가인지, 하이엔드급인지 정도는 생각해 볼 수 있었음.

[프로젝트 KPT 회고]

✅ 1. KEEP – 앞으로도 유지할 점

① 데이터 기반 설계 접근 방식 유지

- 상식적으로 알고 있는 규칙 기반 추천이 아니라, **EDA → 기준 수립 → SQL 로직 구현 → 결과 검증**의 전체 프로세스를 체계적으로 수행하며, 실제 데이터가 가진 분포와 값 등을 고려한 기준 설정은 유효했다고 보여짐

② SQL만으로도 충분히 강력한 분석/추천 시스템 구현 가능함을 확인

- 복잡한 모델 없이도 정규표현식, 분석 함수(**ROW_NUMBER**), 집계, **STRING_AGG**, **CASE** 등을 잘 활용하면 현실적인 추천 시스템을 구현할 수 있다는 교훈을 얻었음.

⚠️ 2. PROBLEM – 아쉬웠던 점 / 한계

① 데이터셋의 통화(currency) 정보 부재

- 가격대 구간을 설정할 때 통화 단위가 명시되지 않아 가격 분포와 브랜드 특성을 바탕으로 추정함. 이는 실제 가격 해석의 정확도가 떨어질 가능성을 남김.

② product_id 중복 행(2~3개)로 인한 전처리 비효율

- 동일 제품이 여러 행으로 분리되어 있어 1번 시스템 쿼리문 작성할 때나 3번 쿼리문 작성 시 전처리 고민이 필요했고 생각보다 앞에서 고민하는 데 시간이 좀 오래 걸렸음.

🚀 3. TRY – 다음 단계에서 개선하거나 시도해볼 점

① 사용자 개인화 정보 추가 시 개인별 맞춤 큐레이션 시스템으로 확장

- 현재는 제품 데이터만 사용했지만, 사용자 행동(조회/구매/좋아요, 위시리스트, 구매정보)이 포함된다면 더 정교하고 흥미로운 추천 시스템 도출이 가능할 것으로 생각함.

예) “이 제품을 산 사람은 이런 것도 같이 샀어요” “위시리스트에 담겨있는 제품이 지금 할인 중이에요”

“구매한 지 1년 지났어요. 살 때 되지 않았나요?”

② 시각화 기반 대시보드 만들어 보기

- 단순 빅쿼리 결과 캡처가 아닌 결과물을 보기 좋게 이미지(도표, 그래프, 인포그래픽 등)으로 시각화하면 스토리텔링 및 발표 효과가 극대화될 텐데, 그걸 다른 툴에서 시도해 볼 시간도 부족하고, 스킬도 여전히 부족한 듯 함. 다음엔 계속 이런 부분을 강화하고 싶음.